

PROYECTO REDES NEURONALES, ARQUITECTURAS Y
APLICACIONES
**Comparison of deep learning models for 1D magnetotelluric
inversion**

Proponente: Jefferson Sánchez Ducuara

Profesor: Arles Rodríguez

Departamento de Matemáticas, Universidad Nacional de Colombia

1. Planteamiento del problema

El **método magnetotelúrico (MT)** es un método geofísico pasivo que utiliza las variaciones naturales del campo electromagnético terrestre para estimar la distribución de resistividad eléctrica del subsuelo [Chave and Jones \[2012\]](#). Gracias a su capacidad para investigar desde decenas de metros hasta varios kilómetros de profundidad, constituye una herramienta ampliamente utilizada en exploración geotérmica, minera, hidrogeológica y en estudios tectónicos [Árnason et al. \[1987\]](#).

El principal desafío del método **MT** radica en el proceso de inversión de los datos medidos. A partir de curvas de resistividad aparente y fase registradas en superficie, es necesario inferir un modelo de resistividad en profundidad, lo que constituye un problema inverso no lineal y sin única solución. Los métodos tradicionales, como la inversión de **Occam** [Constable et al. \[1987\]](#), requieren procesos iterativos de optimización y el cálculo repetido de sensibilidades, lo que implica elevados costos computacionales y una dependencia importante del modelo inicial [Puzirev \[2019\]](#).

En los últimos años, el aprendizaje profundo ha surgido como una alternativa prometedora para este tipo de problemas [Saibi et al. \[2026\]](#). En lugar de resolver la inversión de manera iterativa para cada nuevo sondeo, una *red neuronal* puede aprender la relación entre las respuestas magnetotelúricas y los modelos de resistividad a partir de un conjunto de entrenamiento, permitiendo obtener predicciones casi instantáneas una vez finalizado el entrenamiento.

En este contexto, [Saibi et al. \[2026\]](#) proponen una comparación sistemática entre tres arquitecturas de aprendizaje profundo — **Long Short-Term Memory (LSTM)**, **Gated Recurrent Unit (GRU)** e **Informer** — para la inversión unidimensional de datos magnetotelúricos. Los modelos son entrenados con un conjunto sintético de 100 000 ejemplos y posteriormente evaluados mediante métricas cuantitativas y datos reales, con el objetivo de determinar cuál arquitectura ofrece un mejor desempeño en la reconstrucción de perfiles de resistividad.

El presente proyecto https://github.com/jesanchezdu/1DMD_inversion tiene como propósito analizar y reproducir dicho estudio, describiendo la metodología empleada para la generación

de datos, el entrenamiento de las redes neuronales y la comparación de sus resultados. Adicionalmente, se discute el potencial de estas técnicas para acelerar la interpretación de datos magnetotelúricos y su posible aplicación en problemas de exploración geotérmica.

2. Trabajos relacionado

El uso de técnicas de aprendizaje automático en geofísica ha crecido significativamente durante la última década, impulsado por la disponibilidad de grandes volúmenes de datos y el incremento en la capacidad computacional. Diversos estudios han demostrado el potencial de las *redes neuronales* para resolver problemas de clasificación, interpretación e inversión geofísica, ofreciendo alternativas más rápidas que los métodos numéricos tradicionales Poulton [2002].

En el campo de la inversión electromagnética, varios autores han explorado el empleo de modelos de aprendizaje profundo para estimar propiedades del subsuelo a partir de datos sintéticos y de campo. Entre ellos, destacan los trabajos de Puzyrev (2019) Puzyrev [2019], quien utilizó *redes neuronales* profundas para inversión electromagnética, y Liu et al. (2021) Liu and Zhang [2021], quienes aplicaron *redes convolucionales* a la inversión de datos magnetotelúricos obteniendo resultados comparables con métodos iterativos convencionales. Asimismo, estudios recientes han incorporado restricciones físicas o arquitecturas recurrentes para mejorar la estabilidad y precisión de las predicciones.

El trabajo de Saibi et al. (2026) Saibi et al. [2026], objeto de este proyecto, amplía estas investigaciones al realizar una comparación sistemática entre tres arquitecturas de aprendizaje profundo — **LSTM**, **GRU** e **Informer** — para la inversión magnetotelúrica unidimensional. A diferencia de estudios centrados en una única arquitectura, los autores evalúan los modelos bajo un mismo conjunto de datos sintéticos, un procedimiento uniforme de entrenamiento y métricas comunes de desempeño, permitiendo identificar las ventajas relativas de cada enfoque. Este estudio constituye una referencia relevante para analizar el potencial del aprendizaje profundo como herramienta de inversión rápida de datos magnetotelúricos.

3. Dataset y características

El experimento principal de este trabajo se apoya en un conjunto de datos sintético generado siguiendo el protocolo descrito en Saibi et al. Saibi et al. [2026]. El dataset comprende 100,000 muestras, cada una representando un sondeo MT completo con 25 períodos logarítmicamente espaciados en el rango de 10^{-3} a 10^3 s. Cada muestra consta de dos componentes de entrada —resistividad aparente y fase— y un perfil de resistividad subsuperficial de 50 capas como salida, con espesores que siguen una progresión geométrica de factor $\alpha = 1,2$ a partir de la profundidad mínima de penetración de la señal. Los valores de resistividad de cada modelo fueron generados mediante distribuciones log-normales con parámetros estadísticos derivados de datos reales de MT, restringidos al rango físicamente plausible de 1 a 10,000 $\Omega \cdot m$, y suavizados capa a capa mediante la relación $\log_{10}(\rho_i) = 0,6 \cdot \log_{10}(\rho_{i-1}) + 0,4 \cdot \log_{10}(\rho_i)$ para garantizar continuidad geológica. Las respuestas de resistividad aparente y fase fueron calculadas a partir de estos modelos usando la solución analítica exacta de la fórmula de recursión de Wait, lo que asegura que cualquier discrepancia entre el modelo verdadero y el invertido sea atribuible

exclusivamente a la capacidad de inversión de la red neuronal. El conjunto fue dividido en 80 % entrenamiento y 20 % validación.




Figura 3.1: Modelo geológico simplificado.

Como extensión al caso de aplicación geotérmica, este trabajo incorpora adicionalmente un conjunto de datos de campo reales provenientes de un área geotérmica en América Latina, cuya identidad se mantiene confidencial por acuerdo con los proveedores de la información. Los datos consisten en archivos EDI procesados —que contienen las curvas de resistividad aparente y fase medidas en superficie— acompañados de sus respectivas inversiones 1D en capas, obtenidas mediante métodos convencionales de inversión y expresadas como perfiles de profundidad-resistividad. Este formato es estructuralmente equivalente al par entrada-salida del dataset sintético, lo que permite aplicar directamente los modelos entrenados sobre datos sintéticos a estas mediciones reales sin modificaciones arquitectónicas. La aplicación a este dataset geotérmico constituye una prueba de transferibilidad de los modelos hacia un contexto geológico distinto al del estudio original, caracterizado por la firma resistiva típica de sistemas hidrotermales de alta temperatura descrita en la introducción.

4. Modelos

4.1. Datos del artículo

Los tres modelos de aprendizaje profundo (**LSTM**, **GRU** e **Informer**) fueron entrenados utilizando el conjunto de datos sintético generado para el problema de inversión magnetotelúrica unidimensional. En todos los casos se observó una disminución progresiva de la función de pérdida tanto en el conjunto de entrenamiento como en el de validación, indicando una convergencia estable del proceso de optimización y una adecuada capacidad de generalización.




Figura 4.1: Curvas de entrenamiento y validación para los modelos LSTM, GRU e Informer.


La comparación con la inversión convencional tipo *Bostick* evidencia que las aproximaciones basadas en aprendizaje profundo pueden ofrecer representaciones del subsuelo más cercanas al modelo de referencia cuando son entrenadas con un conjunto de datos suficientemente representativo. En particular, el modelo **Informer** mostró el mejor desempeño global en este estudio, mientras que **LSTM** y **GRU** constituyen alternativas competitivas pero con menor capacidad para reproducir estructuras profundas complejas.

En conjunto, estos resultados demuestran que las técnicas de aprendizaje profundo son una herramienta prometedora para la inversión rápida de datos magnetotelúricos. Sin embargo, también ponen de manifiesto la importancia de emplear conjuntos de entrenamiento diversos y representativos, ya que la precisión de las predicciones en profundidad depende en gran medida de la calidad y cobertura de los modelos sintéticos utilizados durante el entrenamiento.


La comparación de las curvas (Figura 4.1) de pérdida muestra que el modelo **Informer** alcanza los menores valores finales de error, mientras que **LSTM** y **GRU** presentan comportamientos muy similares entre sí. Además, la proximidad entre las curvas de entrenamiento y validación sugiere que ninguno de los modelos experimentó sobreajuste significativo durante el entrenamiento.

Para evaluar el desempeño sobre datos reales, las redes entrenadas se aplicaron a los sondeos **3D01.edi** y **3D02.edi**, comparando los perfiles de resistividad estimados con los modelos de referencia. En ambos casos, las arquitecturas recurrentes (**LSTM** y **GRU**) lograron reproducir parcialmente las variaciones de resistividad del subsuelo, aunque mostraron discrepancias importantes en las mayores profundidades, donde tienden a introducir anomalías conductivas que no están presentes en el modelo de referencia.


Como se puede ver (Figura 4.2) el modelo **Informer** presentó un comportamiento más consistente, reproduciendo de forma más adecuada la tendencia general de los perfiles de resistividad y mostrando una mejor correspondencia en las zonas de transición entre unidades conductivas y resistivas. Esta observación coincide con las métricas cuantitativas obtenidas, donde Informer alcanzó el menor error cuadrático medio ($RMSE$) y los mayores valores del coeficiente de determinación R^2 y del índice de similitud estructural ($SSIM$).




(a) LSTM - 3D01




(b) LSTM - 3D02




(c) GRU - 3D01



(d) GRU - 3D02



(e) Informer - 3D01



(f) Informer - 3D02

Figura 4.2: Comparación entre los perfiles de resistividad predichos por los modelos LSTM, GRU e Informer para los sondeos 3D01 y 3D02. La línea azul corresponde a la predicción del modelo y la línea discontinua gris al modelo de referencia. Fuente: elaboración propia.

4.2. Datos propios

4.2.1. Curvas de entrenamiento (LSTM, GRU, Informer)

Los tres modelos convergen de forma estable sin sobreajuste — las curvas de entrenamiento y validación van prácticamente paralelas en las 100 épocas. El modelo **Informer** parte de una pérdida inicial menor (0.41) que **LSTM** (1.0) y **GRU** (0.95), lo que sugiere que su mecanismo de atención requiere menos épocas para capturar la estructura global de los datos. Sin embargo, **LSTM** y **GRU** alcanzan pérdidas de validación finales similares (0.12), mientras que el **Informer** se estabiliza algo más arriba (0.10 de validación pero con mayor brecha train-val).

4.2.2. Comparación de métricas

El resultado más llamativo es que el **Informer** supera a **LSTM** y **GRU** en los tres indicadores de los datos propios que hacen referencia a un contexto geotérmico — $R^2 \approx 0,79$, $RMSE \approx 0,27$, $SSIM \approx 0,87$ — mientras que en el artículo original el LSTM era el mejor. Esto es un hallazgo: los datos geotérmicos de alta resistividad superficial (*SR0095/SR0096*) tienen contrastes espectrales de largo alcance que el mecanismo de atención del **Informer** captura mejor que las dependencias secuenciales locales de **LSTM** y **GRU**. La transformada de Bostick queda por debajo de los tres modelos de DL en todos los indicadores, confirmando la superioridad del enfoque de aprendizaje profundo incluso en un contexto geológico diferente al de entrenamiento.





Figura 4.3: Comparación de métricas de los modelos LSTM, GRU y Informer.


4.2.3. Perfiles SR0095 — transferibilidad geotérmica

LSTM captura razonablemente la tendencia general de resistividad media (100–300 $\Omega \cdot m$) entre 100 y 10,000 m , pero subestima los contrastes en profundidades mayores a 50,000 m donde el modelo verdadero muestra un incremento resistivo. **GRU** reproduce mejor las variaciones en el rango 100–10,000 m pero sobreestima sistemáticamente las capas más profundas llegando a valores de 10,000 $\Omega \cdot m$ no presentes en el modelo verdadero. **Informer** es el más conservador — mantiene resistividades en el rango 100–500 $\Omega \cdot m$ hasta 10,000 m con buen acuerdo general, aunque tampoco captura el incremento profundo.


El modelo verdadero de *SR0095* muestra resistividades de $30\text{--}700\ \Omega \cdot m$, coherentes con un ambiente geotérmico de temperatura moderada a alta. Los tres modelos **DL** identifican correctamente el orden de magnitud de resistividad pero no resuelven los detalles finos de las capas someras ($\leq 100\ m$) — limitación esperable dado que el dataset sintético tiene resolución logarítmica que privilegia profundidades intermedias.



(a) Predicción con GRU



(b) Predicción con Informer




(c) Predicción con LSTM

Figura 4.4: Comparación de los resultados obtenidos con los modelos GRU, Informer y LSTM para la estación SR0095.


4.2.4. Perfiles SR0096 — caso de alta resistividad anómala

SR0096 representa el caso más desafiante: el modelo verdadero presenta resistividades extremadamente altas en superficie ($10,000\text{--}100,000\ \Omega \cdot m$) seguidas de una zona conductora profunda ($0.5\text{--}10\ \Omega \cdot m$ entre 500 y $10,000\ m$). Esta firma está fuera del rango del dataset sintético ($1\text{--}10,000\ \Omega \cdot m$), lo que explica por qué ningún modelo la reproduce fielmente. Sin embargo,


Informer e **LSTM** logran identificar la zona conductora profunda (valores $10\text{--}100\ \Omega \cdot m$ en el rango correcto de profundidad), lo que es notable dado que aprendieron exclusivamente de datos sintéticos calibrados con otro sitio. **GRU** falla en este sitio — no detecta la zona conductora. Esto sugiere que las resistividades superficiales anómalas de *SR0096* pueden estar relacionadas con efectos estáticos o con un contexto geológico (posiblemente rocas ígneas resistivas en superficie) que requeriría un dataset sintético específicamente diseñado para esos rangos.



(a) Predicción con GRU



(b) Predicción con Informer



(c) Predicción con LSTM

Figura 4.5: Comparación de los resultados obtenidos con los modelos GRU, Informer y LSTM para la estación SR0095.

5. Conclusiones

A diferencia del artículo original donde **LSTM** dominó, en el contexto geotérmico latinoamericano el **Informer** logra mejor desempeño, lo que sugiere que la arquitectura óptima depende del

tipo de ambiente geológico y del rango de resistividades presente en los datos de entrenamiento.

Cuadro 1: Comparación del desempeño de los modelos evaluados.

Modelo	RMSE	R^2	SSIM
LSTM	0.31	0.72	0.82
GRU	0.30	0.73	0.84
Informer	0.27	0.79	0.87
Bostick	0.47	0.16	0.60

Referencias

- A.D. Chave and A.G. Jones. The magnetotelluric method: Theory and practice. *Cambridge University Press.*, 2012.
- S.C. Constable, R.L. Parker, and C.G. Constable. Occam’s inversion: A practical algorithm for generating smooth models from electromagnetic sounding data. *Geophysics*, 52:289–300, 1987.
- Xi Z. Wang H. Liu, W. and R. Zhang. Two-dimensional deep learning inversion of magnetotelluric sounding data. *Geophysics*, Eng. 18:627–641, 2021.
- M.M. Poulton. Neural networks as an intelligence amplification tool: A review of applications. *Geophysics*, 67:979–993, 2002.
- V. Puzyrev. Deep learning electromagnetic inversion with convolutional neural networks. *Geophysics*, Int. 218:817–832, 2019.
- H Saibi, A Hireche, T Tsuji, M. Y. Ali, and Ahmad A. B. Comparison of deep learning models for 1d magnetotelluric inversion. *Applied Computing and Geosciences*, 29:100320, 2026.
- K. Árnason, Ó. G. Flóvenz, and K. Saemundsson. Resistivity structure of the upper crust in iceland. *Journal of Geophysical Research*, 96(B6):5943–5952, 1987.